Modello	Categoria Principale	Sottocategoria / Utilizzo
tev1:0.8b	Sicurezza Informatica	Red Team / Pentesting
tev1:4b	Sicurezza Informatica	Red Team Avanzato
nexus-security (x2)	Sicurezza Informatica	Analisi Vulnerabilità (CVE)
dolphin-mistral:7b	Sicurezza / Uncensored	Red Teaming / Security Research
dolphin-llama3:8b	Sicurezza / Uncensored	Red Teaming / Security Research
llama2-uncensored	Sicurezza / Uncensored	Security Research
gemma-1B-LinuxCLI	SysAdmin / Coding	Comandi Linux / Bash Scripting
qwen2.5-coder:1.5b	Programmazione	Coding Generale (Veloce)
qwen2.5-coder:3b	Programmazione	Coding Generale (Bilanciato)
kirito1/qwen3-coder:4b	Programmazione	Coding Generale (Edge)
starcoder2:3b	Programmazione	Coding Generale
starcoder2:3b-q3_K_L	Programmazione	Coding Generale (Ottimizzato)
deepseek-coder:1.3b	Programmazione	Script veloci / Autocompletamento
deepseek-coder:6.7b	Programmazione	Debugging Complesso
deepseek-coder:6.7b-q4	Programmazione	Debugging Complesso (Quantizzato)
codellama:7b	Programmazione	Coding Generale
granite4:7b-a1b-h	Programmazione	Coding / MoE efficiente
gemma4:e2b	Programmazione / Edge	Coding Leggero / Edge
gemma4-e2b-claude-coder	Programmazione	Agente per Claude Code
deepseek-r1:1.5b	Pensiero Profondo	Reasoning / Chain-of-Thought
phi3:mini	Pensiero Profondo	Logica Compatta
phi3:3.8b	Pensiero Profondo	Logica Compatta

qwen3-8b-32k	Pensiero Profondo	Contesto Lungo / Reasoning
llama3-gradient	Pensiero Profondo	Contesto Ultra-Lungo
translategemma:4b	Traduzioni	Traduzione Pura
qwen2.5:7b	Traduzioni	Traduzione Contestuale
qwen2.5vl:3b	Visione (Multimodale)	Visione / OCR
moondream:latest	Visione (Multimodale)	Visione Base
nomic-embed-text	Embeddings / RAG	Database Vettoriali
embeddinggemma	Embeddings / RAG	Ricerca Semantica
llama3.2:3b	Chat Generale	Assistente Quotidiano
llama3.2:latest	Chat Generale	Assistente Quotidiano
mistral:7b-instruct	Chat Generale	Scrittura / Istruzioni
nous-hermes2	Chat Generale	Chat Avanzata
qwen2.5:0.5b	Chat Generale	Routing / Test ultra-leggeri
qwen2.5:1.5b	Chat Generale	Chat Leggera
qwen3:1.7b	Chat Generale	Chat Leggera
qwen3:4b	Chat Generale	Chat Bilanciata
qwen3:8b	Chat Generale	Chat Avanzata
qwen3-8b-fast	Chat Generale	Chat Avanzata (Ottimizzata)
qwen3.5:4b	Chat Generale	Chat Bilanciata (Nuova Gen)
qwen3.5-16k	Chat Generale	Contesto Medio
qwen3.5:latest	Chat Generale	Chat Avanzata
granite4:1b	Chat Generale	Chat Ultra-Leggera
gemma3:270m	Chat Generale	Test / Micro-modello
antonio-gemma3-evo	Chat Generale	Fine-tuning Community
gemma4:31b-cloud	Cloud	Ragionamento Avanzato
deepseek-v4-flash	Cloud	Coding / Ragionamento
gemini-3-flash	Cloud	Ragionamento / Multimodale
qwen3-next:80b-cloud	Cloud	Massima Intelligenza

Entro 4GB VRAM	Dimensione
Sì	833 MB
No (4.5 GB)	4.5 GB
Sì	986 MB
No (4.1 GB)	4.1 GB
No (4.7 GB)	4.7 GB
Sì (borderline)	3.8 GB
Sì	2.0 GB
Sì	986 MB
Sì	1.9 GB
Sì (borderline)	2.6 GB
Sì	1.7 GB
Sì	1.7 GB
Sì	776 MB
No (3.8 GB)	3.8 GB
No (4.1 GB)	4.1 GB
Sì (borderline)	3.8 GB
No (4.2 GB)	4.2 GB
No (4.6 GB)	4.6 GB
No (7.2 GB)	7.2 GB
Sì	1.1 GB
Sì	2.2 GB
Sì	2.2 GB

No (5.2 GB)	5.2 GB
No (4.7 GB)	4.7 GB
Sì (borderline)	3.3 GB
No (4.7 GB)	4.7 GB
Sì	3.2 GB
Sì	1.7 GB
Sì	274 MB
Sì	621 MB
Sì	2.0 GB
Sì	2.0 GB
No (4.4 GB)	4.4 GB
No (6.1 GB)	6.1 GB
Sì	397 MB
Sì	986 MB
Sì	1.4 GB
Sì	2.5 GB
No (5.2 GB)	5.2 GB
No (5.2 GB)	5.2 GB
Sì (borderline)	3.3 GB
Sì (borderline)	3.3 GB
No (6.6 GB)	6.6 GB
Sì	3.3 GB*
Sì	291 MB
Sì	720 MB
Cloud	-
Cloud	-
Cloud	-
Cloud	-